

Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский ядерный университет «МИФИ»

Курсовая работа
по дисциплине «Классическое машинное обучение»

**Прогнозирование эффективности химических соединений против
вируса гриппа**

Выполнил: Дмитрий Гуленко

Группа: _____

Проверил: _____

Москва, 2026

Оглавление

Введение

1. Постановка задачи, данные и исследовательские гипотезы

2. Методология и применяемые модели

3. Результаты моделирования и сравнительный анализ

Заключение

Введение

Создание нового лекарственного препарата является длительным и дорогостоящим процессом. На ранних этапах разработки требуется определить перспективные химические соединения, синтезировать их, провести биологические испытания и оценить не только активность против вируса, но и токсичность для клеток. Машинное обучение не заменяет лабораторный эксперимент, но может ускорить первичный скрининг и помочь выбрать вещества, которые разумнее проверять в первую очередь.

В данной работе рассматривается задача прогнозирования эффективности химических соединений против вируса гриппа. Химиками предоставлена таблица из 1001 наблюдения. Для каждого соединения известны числовые молекулярные дескрипторы и три целевые величины: IC50, CC50 и SI. Все эти показатели важны для отбора кандидатов, но отражают разные стороны качества соединения.

IC50 показывает концентрацию соединения, при которой вирусная активность подавляется наполовину. Чем меньше IC50, тем выше противовирусная активность вещества. CC50 показывает концентрацию, при которой соединение становится токсичным для половины клеток. Для CC50 желательны большие значения, так как они означают меньшую токсичность. SI, или индекс селективности, рассчитывается как отношение CC50 к IC50 и характеризует окно безопасности: чем выше SI, тем лучше соединение сочетает активность против вируса и безопасность для клеток.

Особенность задачи состоит в том, что SI является производной величиной. Если при прогнозировании SI оставить среди признаков IC50 и CC50, модель фактически получит готовый ответ. Поэтому одна из ключевых методических задач работы - построить модели без утечки данных и честно оценить, насколько молекулярные дескрипторы сами по себе позволяют прогнозировать эффективность соединений.

Цель работы - провести разведочный анализ данных, построить несколько моделей классического машинного обучения для каждой из семи постановок задачи, сравнить качество моделей и сформулировать практические выводы о применимости полученных решений для отбора перспективных соединений.

1. Постановка задачи, данные и исследовательские гипотезы

1.1. Описание исходных данных

Исходная таблица содержит 1001 строку и 214 столбцов. Три целевыми переменными являются IC50, mM, CC50, mM и SI. Помимо них присутствуют 210 числовых молекулярных дескрипторов и технический столбец-индекс, который не должен использоваться как признак при обучении моделей.

Пропусков в данных немного: всего 36 ячеек, и все они находятся в признаках. Целевые переменные пропусков не содержат. Дубликатов строк не обнаружено. Нечисловых признаков в таблице нет, поэтому отдельное кодирование категориальных переменных не требуется.

Разведочный анализ выявил 18 константных признаков. Такие признаки не несут информации, поскольку имеют одно и то же значение для всех соединений. В EDA они явно фиксируются как нерелевантные, а при моделировании удаляются из матрицы признаков.

Показатель	Среднее	Медиана	Std	Min	Max
IC50, mM	222.805	46.585	402.170	0.004	4128.529
CC50, mM	589.111	411.039	642.868	0.701	4538.976
SI	72.509	3.846	684.483	0.011	15620.600

Таблица 1 - Описательные статистики целевых переменных

Все три целевые переменные имеют правостороннюю асимметрию. Особенно выражена она у SI: среднее значение примерно 72.5, медиана около 3.85, а максимум достигает 15620.6. Это означает, что небольшое число экстремальных соединений существенно влияет на средние значения и метрики, чувствительные к крупным ошибкам.

По правилу межквартильного размаха выбросы обнаружены во всех трёх целях: для IC50 - 147 наблюдений, для CC50 - 39 наблюдений, для SI - 125 наблюдений. Автоматически удалять такие строки нецелесообразно, поскольку в химико-биологических данных экстремальные значения могут соответствовать реальным соединениям. Поэтому в работе выбросы

сохраняются, а их влияние учитывается через выбор метрик и интерпретацию результатов.




Рисунок 1 - Распределение целевых переменных в шкале log1p




Рисунок 2 - Корреляции Спирмена между целевыми переменными

1.2. Постановки задач

В работе решаются семь задач. Первые три являются задачами регрессии: необходимо предсказать численные значения IC50, CC50 и SI. Остальные четыре являются задачами бинарной классификации: нужно определить, превышает ли IC50 медиану обучающей выборки, превышает ли CC50 медиану обучающей выборки, превышает ли SI медиану обучающей выборки и превышает ли SI фиксированное значение 8.

Медианные пороги строятся только по обучающей части данных. Это важно, поскольку медиана всей выборки содержала бы информацию о тестовой части и создавала бы пусть небольшую, но настоящую утечку. Для задачи $SI > 8$ порог задан предметно и не оценивается по данным.

1.3. Исследовательские гипотезы

Гипотеза 1. Молекулярные дескрипторы содержат полезный сигнал для прогнозирования IC50 и CC50, но качество будет умеренным из-за шума биологических измерений и небольшого размера выборки.

Гипотеза 2. CC50 должна предсказываться лучше, чем IC50 и SI, если токсичность сильнее связана с устойчивыми структурными дескрипторами.

Гипотеза 3. Прямая регрессия SI будет наиболее сложной задачей, поскольку SI является отношением двух величин и имеет сильные выбросы.

Гипотеза 4. Классификационные постановки, особенно $SI > 8$, будут практичнее прямой регрессии SI, так как для отбора соединений часто важнее выделить перспективную группу, чем точно восстановить численное значение индекса.

2. Методология и применяемые модели

2.1. Защита от утечки данных

Главное методическое решение работы - во всех семи задачах из признаков удаляются все три целевые переменные: IC50, mM, CC50, mM и SI. Это делается независимо от того, какая именно цель предсказывается. Также из признаков удаляется технический столбец-индекс.

Такой подход нужен из-за определения SI. Если при прогнозировании SI использовать IC50 и CC50, модель могла бы почти напрямую восстановить целевую переменную. Если при прогнозировании IC50 или CC50 оставить SI, возникла бы обратная утечка через производный показатель. Поэтому все целевые колонки исключаются одновременно.

Дополнительно в EDA проверялась связь отдельных дескрипторов с целями. Максимальные абсолютные корреляции Спирмена между отдельным признаком и целью находятся примерно в диапазоне 0.22-0.30, что не похоже на переименованный дубликат целевой переменной.

2.2. Разбиение, препроцессинг и подбор параметров

Для оценки качества используется фиксированное разбиение train/test в пропорции 80/20 с random_state=42. Тестовая часть применяется только один раз - для финальной оценки моделей после подбора гиперпараметров.

Пропуски в признаках заполняются медианой. Для линейных моделей и KNN дополнительно применяется стандартизация признаков, поскольку эти алгоритмы чувствительны к масштабу. Для деревьев масштабирование не требуется. Все этапы предобработки включены в Pipeline, поэтому медианы и параметры стандартизации вычисляются только на обучающих фолдах, а не на всей выборке.

Подбор гиперпараметров выполняется через GridSearchCV с кросс-валидацией на обучающей части. Для регрессии основная метрика подбора - отрицательный MAE, для классификации - ROC-AUC. Такой выбор

соответствует задачам: в регрессии важно контролировать среднюю ошибку, а в классификации - качество ранжирования объектов по вероятности положительного класса.

2.3. Используемые модели

В каждой задаче сравниваются пять моделей. Первая - базовая модель DummyRegressor или DummyClassifier. Она нужна как нижняя граница качества: если сложная модель не превосходит базовую, значит полезного сигнала в признаках почти нет или постановка выбрана неудачно.

Для регрессии используется Ridge на логарифмированной шкале цели. Логарифмирование уменьшает влияние больших значений и делает распределение более устойчивым для линейной модели. Для классификации аналогичную роль простого линейного ориентира играет логистическая регрессия.

KNN оценивает объект через похожие соединения и может быть полезен, если близость в пространстве дескрипторов действительно отражает близость биологической активности. ExtraTrees и градиентный бустинг представляют ансамблевые древесные модели. Они хорошо подходят для табличных данных, способны учитывать нелинейности и взаимодействия признаков и не требуют жёстких предположений о форме зависимости.

2.4. Метрики качества

Для регрессии используются MAE, RMSE, медианная абсолютная ошибка и R2. MAE выбрана как основная метрика, потому что она интерпретируема в единицах целевой переменной и менее чувствительна к экстремальным ошибкам, чем RMSE. RMSE дополнительно показывает влияние крупных промахов, что особенно важно при выбросах SI.

Для классификации используются ROC-AUC, PR-AUC, accuracy, balanced accuracy, F1, precision и recall. При сбалансированных задачах по медиане

accuracy и F1 информативны, но для $SI > 8$ положительный класс составляет около 35.8 %, поэтому особенно важны ROC-AUC и PR-AUC.

3. Результаты моделирования и сравнительный анализ

3.1. Регрессия IC50

Модель	MAE	RMSE	Median AE	R2
KNN	215.254	443.809	63.567	0.410
Ridge (log-цель)	223.677	480.847	56.791	0.307
ExtraTrees	225.986	445.143	86.624	0.406
Градиентный бустинг	227.605	438.502	92.618	0.424
DummyRegressor	278.881	629.994	42.488	-0.190

Таблица 2 - Результаты регрессии IC50

Наименьший MAE показывает KNN: 215.254. При этом градиентный бустинг имеет лучший R2 и RMSE, что говорит о более устойчивом объяснении дисперсии при немного большей средней абсолютной ошибке. Все содержательные модели превосходят базовый прогноз по медиане.

Результат по IC50 следует оценивать как умеренный. R2 около 0.41-0.42 означает, что признаки объясняют менее половины дисперсии. Это подтверждает первую гипотезу: полезный сигнал есть, но задача не является простой.

3.2. Регрессия CC50

Модель	MAE	RMSE	Median AE	R2
ExtraTrees	262.252	449.160	130.338	0.611
KNN	270.534	474.803	107.301	0.565
Градиентный бустинг	301.614	475.519	194.699	0.564
Ridge (log-цель)	377.804	630.535	203.094	0.233
DummyRegressor	507.246	762.638	347.428	-0.122

Таблица 3 - Результаты регрессии CC50

Для CC50 лучшей моделью является ExtraTrees. Она показывает одновременно лучший MAE, RMSE и R2. Значение R2 равно 0.611, что заметно выше, чем для IC50.

Этот результат подтверждает вторую гипотезу: CC50 действительно восстанавливается из дескрипторов лучше остальных непрерывных целей. Вероятно, часть структурных свойств молекул устойчивее связана с токсичностью, чем с противовирусной активностью.

3.3. Регрессия SI

Модель	MAE	RMSE	Median AE	R2
Ridge (log-цель)	179.923	1424.976	4.762	-0.011
DummyRegressor	180.856	1428.462	3.039	-0.016
KNN	183.519	1368.805	7.447	0.067
ExtraTrees	187.083	1354.415	8.858	0.087
Градиентный бустинг	189.132	1359.068	10.320	0.080

Таблица 4 - Результаты регрессии SI

Регрессия SI оказалась самой слабой из трёх регрессионных задач. Формально лучший MAE у Ridge на логарифмированной шкале, но выигрыш относительно DummyRegressor минимален. Древесные модели дают небольшой положительный R2, однако он остаётся около 0.08-0.09.

Основная причина - экстремальная асимметрия SI. При медиане около 3.85 в данных есть значения до 15620.6. Несколько таких наблюдений резко увеличивают RMSE и делают точное численное прогнозирование SI нестабильным. Третья гипотеза подтверждается: прямую регрессию SI нельзя считать надёжной практической постановкой.

3.4. Классификация IC50 выше медианы

Порог бинаризации равен 46.793 и рассчитан по обучающей части. Доля положительного класса на тесте составляет 0.498.

Модель	ROC-AUC	PR-AUC	Accuracy	Bal. acc.	F1
Градиентный бустинг	0.762	0.745	0.682	0.682	0.701
Логистическая регрессия	0.752	0.771	0.701	0.702	0.712
ExtraTrees	0.736	0.745	0.706	0.707	0.726
KNN	0.711	0.702	0.667	0.667	0.679
DummyClassifier	0.500	0.498	0.502	0.500	0.000

Таблица 5 - Классификация IC50 выше медианы

Лучший ROC-AUC у градиентного бустинга - 0.762. Логистическая регрессия близка по ROC-AUC и имеет даже более высокий PR-AUC. Качество можно считать умеренным и согласующимся с результатами регрессии IC50.

3.5. Классификация CC50 выше медианы

Порог бинаризации равен 410.059. Доля положительного класса на тесте составляет 0.502.

Модель	ROC-AUC	PR-AUC	Accuracy	Bal. acc.	F1
ExtraTrees	0.859	0.870	0.741	0.741	0.755
Градиентный бустинг	0.853	0.860	0.711	0.711	0.726
Логистическая регрессия	0.839	0.860	0.736	0.736	0.756
KNN	0.826	0.782	0.751	0.751	0.771
DummyClassifier	0.500	0.502	0.498	0.500	0.000

Таблица 6 - Классификация CC50 выше медианы

Это самая сильная классификационная постановка. ExtraTrees достигает ROC-AUC 0.859 и PR-AUC 0.870. Результат хорошо согласуется с регрессией CC50 и подтверждает, что токсичность по данным дескрипторам отделяется лучше других целей.

3.6. Классификация SI выше медианы

Порог бинаризации равен 3.823. Доля положительного класса на тесте составляет 0.502.

Модель	ROC-AUC	PR-AUC	Accuracy	Bal. acc.	F1
Градиентный бустинг	0.684	0.716	0.657	0.657	0.639
KNN	0.680	0.652	0.662	0.662	0.670
ExtraTrees	0.664	0.669	0.657	0.657	0.642
Логистическая регрессия	0.655	0.665	0.622	0.622	0.620
DummyClassifier	0.500	0.502	0.498	0.500	0.000

Таблица 7 - Классификация SI выше медианы

Качество умеренное: лучший ROC-AUC равен 0.684. Это лучше случайного уровня, но заметно слабее, чем для CC50. Результат показывает, что даже бинарное разделение SI по медиане остаётся трудной задачей.

3.7. Классификация SI больше 8

Порог фиксирован и равен 8.0. Доля положительного класса на тесте составляет 0.358, поэтому ассигасу сама по себе недостаточна для оценки качества.

Модель	ROC-AUC	PR-AUC	Accuracy	Bal. acc.	F1
Градиентный бустинг	0.738	0.667	0.711	0.665	0.554
ExtraTrees	0.734	0.664	0.682	0.657	0.562
KNN	0.725	0.610	0.701	0.669	0.571
Логистическая регрессия	0.670	0.511	0.632	0.627	0.543
DummyClassifier	0.500	0.358	0.642	0.500	0.000

Таблица 8 - Классификация SI больше 8

Лучший ROC-AUC у градиентного бустинга - 0.738, PR-AUC равен 0.667. Это заметно выше случайного уровня и выше базового прогноза большинством. Однако F1 остаётся умеренным, что означает пропуск части перспективных соединений.

С практической точки зрения эта постановка полезнее прямой регрессии SI. Для первичного скрининга часто достаточно отделить соединения с потенциально высоким индексом селективности, а затем передать их на дополнительную лабораторную проверку. Четвёртая гипотеза подтверждается частично: классификация $SI > 8$ действительно выглядит более устойчивой, но не даёт идеального отбора.

3.8. Сравнение задач

Общая картина результатов согласована между регрессией и классификацией. CC50 является наиболее предсказуемой целью. IC50 предсказывается хуже, но всё же с заметным выигрышем относительно базовой модели. SI остаётся самой проблемной целью как в регрессии, так и в классификации.

Ансамбли деревьев чаще всего оказываются лучшим или близким к лучшему решением. ExtraTrees особенно устойчив для CC50, а градиентный бустинг показывает лучшие результаты в большинстве классификационных задач. KNN оказался конкурентоспособен для IC50 по MAE, но как универсальное решение менее стабилен.

Результаты не следует трактовать как готовую систему принятия решений о лекарственных препаратах. Это инструмент предварительного ранжирования

и отбора кандидатов. Перед практическим использованием модели требуют внешней валидации на новых соединениях и согласования с химиками допустимых диапазонов IC50, CC50 и SI.

Заключение

В работе проведён разведочный анализ данных о 1001 химическом соединении и построены модели классического машинного обучения для семи задач: трёх регрессий и четырёх классификаций. Данные оказались пригодны для моделирования, но обладают важными ограничениями: небольшим числом объектов, слабыми индивидуальными связями признаков с целями, асимметричными распределениями и выраженными выбросами, особенно у SI.

Первая гипотеза подтвердилась частично. Молекулярные дескрипторы действительно содержат полезный сигнал для IC50 и CC50, но качество остаётся умеренным. Для IC50 лучший MAE составил около 215, а R2 лучших моделей находится около 0.41-0.42.

Вторая гипотеза подтвердилась. CC50 оказалась самой предсказуемой непрерывной целью: ExtraTrees показал MAE около 262 и R2 около 0.61. В классификации CC50 выше медианы также получен лучший результат среди бинарных задач: ROC-AUC около 0.86.

Третья гипотеза подтвердилась полностью. Прямая регрессия SI является наиболее слабой постановкой. Лучшие модели лишь немного превосходят базовый прогноз по MAE, а R2 остаётся близким к нулю. Причина связана с природой SI как отношения CC50 к IC50 и с экстремальными выбросами.

Четвёртая гипотеза также в целом подтвердилась. Классификация $SI > 8$ даёт более практически применимый результат, чем точная регрессия SI: лучший ROC-AUC равен примерно 0.738. Это не идеальная модель, но она способна выделять перспективные соединения лучше случайного отбора.

Наиболее устойчивыми моделями в работе стали ExtraTrees и градиентный бустинг. Они хорошо подходят для табличных данных с большим числом числовых дескрипторов и способны учитывать нелинейные зависимости. При этом KNN и линейные модели полезны как дополнительные

ориентиры и помогают понять, насколько сложные методы действительно дают прирост.

Главное практическое ограничение состоит в том, что результаты получены на одной выборке из 1001 соединения. Для применения в реальной разработке лекарств необходима внешняя проверка на новых соединениях, анализ важности признаков и консультация с химиками по предметной интерпретации найденных закономерностей.